

Rapport d'analyse exploratoire et de modelisation

Projet : Systeme intelligent de prediction du risque de credit BMCE

1. Objectif du projet

L'objectif du projet est de construire une solution de scoring credit permettant d'estimer le risque associe a une nouvelle demande de credit. Le systeme combine :

- une analyse exploratoire des donnees clients ;
- un nettoyage et un feature engineering metier ;
- une comparaison de modeles de classification ;
- un traitement du desequilibre de classes avec SMOTE ;
- une optimisation des hyperparametres avec GridSearchCV ;
- une API FastAPI et un dashboard Streamlit pour l'exploitation.

La variable cible est target_default :

- 0 : avis favorable ;
- 1 : dossier risque, correspondant a Avis defavorable, Etude approfondie ou Non eligible.

Cette definition permet de regrouper les dossiers qui necessitent une attention risque, au lieu de ne considerer que les refus stricts.

2. Description generale du dataset

Le fichier utilise est dataset_credit_bmce_100k.csv.

Remarque importante sur les types de credit : dans le CSV, la modalite Personnel correspond au credit a la consommation/personnel. Elle regroupe des objets comme sante, mariage, voyage, equipement maison, besoin personnel ou etudes. Dans le dashboard, ce type est affiche plus clairement sous le libelle Consommation / Personnel.

Indicateur	Valeur
Nombre de lignes	100 000
Nombre de colonnes brutes	47
Nombre de colonnes apres creation de la cible	48
Taux de dossiers risques	44,36 %
Taux de valeurs manquantes dans le CSV brut	18,43 %
Taux apres creation de la cible	18,04 %
Doublons detectes	0

La repartition de la cible apres construction est :

Classe	Signification	Nombre
0	Avis favorable	55 638
1	Avis defavorable, etude approfondie ou non eligible	44 362

La distribution initiale par decision bancaire est :

Decision	Nombre
Avis favorable	55 638
Avis defavorable	26 127
Etude approfondie	16 719
Non eligible	1 516

Dataset card et tracabilite

Champ	Valeur
Nature	Jeu de demandes de credit entierement synthetique
Unite d'observation	Une demande simulee
Periode simulee	2023-01-01 au 2026-03-26
Taille du fichier	25 557 339 octets, environ 24,37 Mio
Empreinte SHA-256	45C23401EA6A9818145D6D388ACC2C782000D01AA18377EA098751A498F17119
Producteur et generateur	Non documentes dans le depot
Licence	Non specifiee

La cible technique target_default est derivee de la decision synthetique. Elle ne represente pas un défaut de remboursement reellement observe. Le nom du fichier ne prouve pas une origine ou une validation par BMCE Bank of Africa. Le jeu sert uniquement a l'experimentation academique, a l'EDA et au prototypage ; il ne doit pas etre utilise pour accepter, refuser ou tarifer un credit reel,

produire un score reglementaire ou conclure sur la population marocaine.

Le depot ne contient ni le script de generation, ni les distributions sources, ni la graine


aleatoire. La generation exacte n'est donc pas reproductible. La dataset card complete, avec le

dictionnaire des 47 variables, la qualite, les biais, la confidentialite et les consignes de

maintenance, se trouve dans DATASET_CARD.md. Elle est egalement integree a l'annexe F du rapport PFE

complet reports/rapport_pfe_complet_fr.md.

Figure associee :



Distribution de la cible

3. Qualite des donnees

L'analyse des valeurs manquantes montre que certaines colonnes sont fortement incompletes. Cela

s'explique par la nature conditionnelle de certaines informations :

- les informations de garantie ne sont presentes que lorsqu'une garantie existe ;
- les variables liees au vehicule ne concernent que les credits auto ;
- les variables liees au bien immobilier ne concernent que les credits immobiliers.

Les colonnes les plus manquantes sont notamment :

Variable	Taux de valeurs manquantes
ratio_couverture	76,79 %
valeur_garantie	76,79 %
type_garantie	76,79 %
garantie_presente	75,27 %
valeur_bien	75,27 %
type_bien	75,27 %
localisation_bien	75,27 %
prix_vehicule	66,94 %
age_vehicule	66,94 %
marque_vehicule	66,94 %

Ces valeurs manquantes ne sont donc pas uniquement des erreurs de saisie. Elles ont une signification métier : toutes les demandes ne concernent pas les memes produits bancaires.

Dans le pipeline de modelisation, les valeurs manquantes sont traitees par :


- imputation par la mediane pour les variables numeriques ;
- imputation par la modalite la plus frequente pour les variables categorielles ;
- encodage OneHotEncoder pour les categories.

4. Analyse exploratoire des variables numeriques

Les distributions suivantes ont ete generees pour analyser le comportement des principales variables selon la cible.

Age

Distribution de age




Distribution age

L'age permet d'observer si certaines tranches de clients presentent un niveau de risque plus eleve.

Il est ensuite transforme en variable categorielle age_bin.

Revenu mensuel


Distribution de revenu_mensuel



Distribution revenu mensuel

Le revenu mensuel est une variable importante dans l'analyse credit. Les revenus plus faibles peuvent etre associes a une capacite de remboursement plus limitee, surtout lorsque les charges et mensualites existantes sont elevees.

Montant du credit




Distribution montant credit

Le montant du credit influence directement le niveau d'exposition de la banque. Il doit etre interprete conjointement avec le revenu, l'apport personnel, la duree et les charges.

Duree du credit


Distribution de duree_mois



Distribution duree

La duree peut reduire la mensualite mais augmenter l'exposition dans le temps. Elle est donc importante dans la lecture du risque global.

Distribution de taux_endettement




Distribution taux endettement

Le taux d'endettement est fortement lie au risque. Toutefois, pour eviter une evaluation trop optimiste, certaines variables tres proches des regles de decision bancaire sont exclues de l'entrainement final lorsqu'elles ressemblent a des sorties de politique interne.

5. Matrice de correlation

La matrice de correlation permet d'identifier les relations lineaires entre variables numeriques.



Matrice de correlation

Les variables les plus correlees avec la cible sont :

| Variable | Correlation absolue avec la cible |

---|---:

| score_default | 0,865 |

| reste_a_vivre | 0,682 |

| dti_calcule | 0,653 |

| taux_endettement | 0,653 |

| mensualite_estimee | 0,531 |

| valeur_garantie | 0,479 |

| valeur_bien | 0,478 |

| ratio_credit_revenu | 0,413 |

| revenu_total | 0,374 |

| revenu_mensuel | 0,351 |

Certaines variables, comme score_default, decision et niveau_risque, sont considerees comme des

variables de fuite de cible. Elles sont donc exclues du modele car elles representent deja une

information issue de la decision finale ou tres proche de celle-ci.

6. Feature engineering

Le feature engineering permet d'ajouter des variables plus expressives a partir des donnees brutes.

Les principales variables creees sont :

Variable creee	Explication
revenu_total	Revenu mensuel + revenu supplementaire
dti_calcule	Ratio mensualites totales / revenu total
reste_a_vivre	Revenu total moins charges et mensualites
taux_epargne	Epargne mensuelle / revenu total
ratio_credit_revenu	Montant du credit / revenu total
incident_ou_retard	Indicateur binaire si incident ou retard de paiement
annee_demande	Annee extraite de la date de demande
mois_demande	Mois extrait de la date de demande
age_bin	Tranche d'age
revenu_bin	Tranche de revenu
montant_credit_bin	Tranche de montant de credit

Ces variables apportent une lecture metier plus riche que les variables brutes. Par exemple, le revenu seul ne suffit pas : il faut le comparer aux charges, aux mensualites existantes et au montant demande.

Les variables metier prises en compte par les modeles avances incluent notamment :

- incidents de paiement sur 12 mois ;
- retards de paiement sur 12 mois ;
- apport personnel ;
- credits en cours ;
- mensualites existantes ;
- charges mensuelles ;
- epargne mensuelle ;
- solde moyen du compte ;
- anciennete bancaire ;
- revenu total ;
- reste a vivre ;
- ratio credit / revenu ;

- indicateur incident ou retard.

7. Preprocessing

Le preprocessing applique avant entraînement comprend :

1. Nettoyage des colonnes et suppression des doublons.
2. Conversion de la date de demande.
3. Construction de la cible target_default.
4. Suppression des variables de fuite :
 - id_demande ;
 - decision ;
 - score_default ;
 - niveau_risque.
5. Exclusion de certaines variables très proches des règles de décision bancaire afin d'éviter un score artificiellement parfait.
6. Imputation des valeurs manquantes.
7. Standardisation des variables numériques.
8. Encodage des variables catégorielles.

8. Desequilibre des classes et SMOTE

Avant SMOTE, l'échantillon d'entraînement contient :

Classe	Nombre
0	8 884
1	7 116

La classe risquée est moins représentée que la classe favorable. Cela peut pousser le modèle à mieux apprendre la classe majoritaire.

Après application de SMOTE sur l'ensemble d'entraînement uniquement :

Classe	Nombre
--------	--------

|---|---:|
| 0 | 8 884 |
| 1 | 8 884 |

SMOTE cree des exemples synthetiques de la classe minoritaire. Il est applique uniquement sur le jeu d'entrainement afin d'eviter toute fuite d'information vers le jeu de test.

Effet attendu :

- meilleure sensibilite aux dossiers risques ;
- amelioration du rappel de la classe 1 ;
- reduction du biais vers les avis favorables.

9. Modeles compares

Trois modeles sont compares :

Regression logistique

La regression logistique est utilisee comme baseline traditionnelle. Elle est simple, interpretable et souvent utilisee comme reference en scoring credit.

Dans ce projet, elle est volontairement limitee a un socle de variables classiques du dossier client. Elle utilise tout de meme :

- SMOTE ;
- GridSearchCV ;
- regularisation L2.

Cette configuration permet de montrer les limites d'une methode statistique traditionnelle face a des modeles non lineaires.

Random Forest

Random Forest est un modele d'ensemble base sur plusieurs arbres de decision. Il gere mieux les relations non lineaires et les interactions entre variables.

Dans le projet, il utilise l'ensemble des variables metier disponibles apres preprocessing.

XGBoost

XGBoost est un modele de boosting performant pour les donnees tabulaires. Il apprend progressivement des arbres corrigeant les erreurs des arbres precedents.

Pour eviter un modele trop parfait, XGBoost est regularise avec :

- profondeur faible ;
- learning rate faible ;
- subsampling ;
- colsample_bytree ;
- regularisation L2 ;
- min_child_weight ;
- gamma.

10. GridSearchCV

GridSearchCV permet de tester plusieurs combinaisons d'hyperparametres et de retenir la meilleure selon le score ROC-AUC.

L'interet de GridSearchCV est de rendre la comparaison plus rigoureuse :

- les parametres ne sont pas choisis manuellement au hasard ;
- chaque modele est optimise sur validation croisee ;
- la comparaison finale est faite sur un jeu de test separe.

Exemples d'hyperparametres optimises :

- C pour la regression logistique ;
- max_depth, min_samples_leaf, n_estimators pour Random Forest ;
- learning_rate, max_depth, reg_lambda, subsample, gamma pour XGBoost.

11. Resultats des modeles

Les chiffres ci-dessous sont recalculés après calibration sigmoïde de chaque modèle. Le seuil de chaque classifieur maximise le F1 sur une période de validation distincte ; le jeu de test reste réservé au calcul final des métriques.

Modele	Accuracy	Precision	Recall	F1	ROC-AUC	Gini	KS
Regression logistique	0,8288	0,7906	0,8297	0,8097	0,9009	0,8018	0,6614
Arbre de decision	0,8205	0,7808	0,8218	0,8008	0,9049	0,8098	0,6441
Random Forest	0,8305	0,7781	0,8588	0,8165	0,9095	0,8189	0,6721
XGBoost	0,8135	0,7587	0,8434	0,7988	0,8940	0,7879	0,6350
LightGBM	0,8505	0,8077	0,8656	0,8356	0,9222	0,8443	0,7071


Interpretation :

- LightGBM obtient la meilleure ROC-AUC (0,9222), le meilleur F1 (0,8356) et le meilleur Brier score (0,1074).
- Random Forest présente la plus faible ECE (0,0171), donc le plus petit écart moyen de calibration selon cette mesure.
- XGBoost atteint une ROC-AUC réelle de 0,8940 après recalibration, mais n'est pas le meilleur modèle de ce protocole.
- Ces résultats restent une validation méthodologique sur données synthétiques, sans prétendre à une validation bancaire réelle.

12. Evaluation detaillee du modele XGBoost recalibre

Courbe ROC

Courbe ROC-AUC réelle sur le jeu de test



Calcul direct sur 4,000 predictions individuelles du jeu de test; aucune courbe reconstruite.

Courbe ROC


Cette courbe est calculee point par point a partir des probabilites recalibrees pour les 4 000

observations du jeu de test. La ROC-AUC obtenue est de 0,8940 (Gini = 0,7879). Elle n'est ni

reconstruite depuis une metrique agregee, ni plafonnee.

Courbe KS


Courbe KS réelle sur le jeu de test



Calcul direct sur 4,000 predictions individuelles du jeu de test; aucune courbe reconstruite.

Courbe KS

Le maximum de l'ecart entre les distributions cumulees est $KS = 0,6350$. Il est atteint pour un score de risque proche de 0,3909. Le calcul traite correctement les ex aequo en utilisant les seuils distincts issus de la courbe ROC.



Calcul direct sur 4,000 predictions individuelles du jeu de test; aucune courbe reconstruite.

Courbe de calibration


La calibration est calculee sur dix groupes de probabilites de meme effectif. Apres recalibration

sigmoide sur validation separee, le Brier score vaut 0,1304 et l'erreur de calibration attendue

(ECE) 0,0334.

Matrice de confusion

Matrice de confusion réelle au seuil 0.4014



Calcul direct sur 4,000 predictions individuelles du jeu de test; aucune courbe reconstruite.

Matrice de confusion

La matrice est calculee directement sur les 4 000 observations du jeu de test au seuil valide de 0,4014. Elle contient 1 773 vrais negatifs, 471 faux positifs, 275 faux negatifs et 1 481 vrais positifs. Elle permet d'analyser :


- les vrais positifs : dossiers risques bien detectes ;
- les vrais negatifs : dossiers favorables bien acceptes ;
- les faux positifs : dossiers favorables classes comme risques ;
- les faux negatifs : dossiers risques classes comme favorables.

Dans le credit, les faux negatifs sont particulierement sensibles car ils peuvent conduire a accepter un dossier risque. Ici, cette lecture reste methodologique : elle ne remplace pas une validation sur donnees bancaires reelles.

13. Analyse des seuils de decision

Le seuil retenu pour XGBoost est 0,4014. Il maximise le F1 sur le jeu de validation reserve au choix du seuil, avant toute consultation des cibles de test.

Analyse réelle du seuil de décision



Calcul direct sur 4,000 predictions individuelles du jeu de test; aucune courbe reconstruite.

Analyse réelle des seuils

| [Seuil](#) | [Effet principal](#) | [Interpretation](#) |

| ---:|---|---|

| 0,30 | Rappel plus eleve | Davantage de dossiers risques sont detectes, au prix de plus de faux

positifs |

| 0,4014 | Seuil valide | Accuracy test 0,8135 ; precision 0,7587 ; rappel 0,8434 ; F1 0,7988 |

| 0,70 | Precision plus elevee | Les alertes sont plus selectives, mais davantage de dossiers

risques peuvent etre manques |

Interpretation :

- Un seuil faible augmente le rappel : le modele detecte plus de dossiers risques.
- Un seuil eleve augmente la precision : les dossiers classes comme risques sont plus selectifs.
- Le seuil final devrait dependre de la politique risque de la banque et etre valide sur donnees


reelles avant tout usage operationnel.

- Le seuil n'a pas ete optimise sur le test : le F1 test de 0,7988 est une mesure finale hors

echantillon.

14. Importance des variables et explicabilite


Importance des variables



Importance des variables

L'importance des variables permet d'identifier les facteurs les plus influents dans la prediction.

Analyse SHAP



SHAP summary

SHAP permet d'expliquer l'impact des variables sur les predictions du modele. Il ne prouve pas une causalite, mais il aide a comprendre pourquoi certains dossiers sont classes comme plus risques.

15. Dashboard et exploitation


Le dashboard Streamlit permet :

- de visualiser les indicateurs globaux du portefeuille ;
- de scorer un nouveau demandeur ;
- d'afficher une jauge de risque ;
- de comparer le demandeur avec des clients similaires ;
- de faire un scoring par lot via upload CSV ;
- de filtrer les clients par ville, type de credit, decision, age et montant ;
- d'exporter les resultats ;
- de suivre les logs des predictions ;
- d'analyser la qualite des donnees.

Cette interface transforme le modele en outil exploitable pour une demonstration metier.

16. Architecture technique

L'architecture du projet suit une logique modulaire :



Architecture systeme

Le flux principal est le suivant :

1. Le fichier CSV contient les demandes de credit.
2. Le module EDA analyse les distributions, correlations et valeurs manquantes.
3. Le feature engineering cree des variables metier plus explicatives.
4. Le pipeline ML applique preprocessing, SMOTE, GridSearchCV et entrainement.
5. Le meilleur modele est sauvegarde dans models/best_model.joblib.
6. FastAPI expose le modele via /predict.
7. Streamlit permet une utilisation metier avec scoring, portefeuille, monitoring et explicabilite.
8. Les predictions sont journalisees pour assurer une tracabilite.

Docker et Docker Compose permettent de lancer l'API et le dashboard dans un environnement reproductible.

17. Explicabilite individuelle

En plus de l'explicabilite globale avec SHAP, le dashboard affiche une lecture individuelle apres chaque prediction.

Cette lecture met en evidence les signaux qui peuvent augmenter ou reduire le risque :

- incidents de paiement ;
- retards de paiement ;
- niveau d'endettement ;
- montant demande par rapport au revenu ;
- apport personnel ;
- reste a vivre ;
- epargne ;
- solde moyen ;
- anciennete bancaire.

Cette partie est importante car un analyste credit ne doit pas seulement voir une probabilite. Il doit aussi comprendre les raisons metier qui expliquent la decision proposee.

18. Logs enrichis et tracabilite

Le dashboard enregistre des logs enrichis dans logs/dashboard_predictions.csv.

Les informations conservees incluent :

- date de prediction ;
- probabilite de risque ;
- score credit ;
- segment de risque ;
- decision ;
- type de credit ;
- montant demande ;

- revenu ;
- charges ;
- incidents ;
- retards ;
- apport ;
- taux d'endettement.

Cette tracabilite est essentielle dans un contexte bancaire pour l'audit, le monitoring et l'analyse future des decisions.

19. Limites du projet

Le projet est volontairement adapte a un contexte PFE. Dans un environnement bancaire reel, plusieurs limites devraient etre traitees :

- les donnees sont synthetiques et ne remplacent pas des donnees bancaires reelles ;
- la validation temporelle pourrait etre renforcee ;
- la calibration mesuree reste imparfaite et devrait etre corrige sur un jeu de validation distinct ;
- le monitoring de drift n'est pas encore industriel ;
- les contraintes reglementaires Bâle, IFRS 9 ou scoring reglementaire ne sont pas couvertes en detail ;
- la decision finale doit rester validee par un expert credit ;
- le modele doit etre audite regulierement pour verifier sa stabilite.

20. Perspectives d'amelioration

Les principales ameliorations possibles sont :

- comparer une calibration sigmoide et une calibration isotone sans utiliser le jeu de test pour l'ajustement ;
- ajouter un monitoring de drift des donnees ;
- suivre la stabilite des variables avec PSI ;
- ajouter des tests automatises ;

- historiser les versions de modeles ;
- connecter le dashboard a une base de donnees ;
- ajouter une authentification ;
- generer un rapport PDF automatique apres chaque scoring ;
- ajouter une explicabilite locale plus avancee avec SHAP par dossier.

21. Conclusion

Le projet montre une chaine complete de scoring credit :

1. Analyse exploratoire du dataset.
2. Construction d'une cible risque.
3. Nettoyage et feature engineering.
4. Traitement du desequilibre avec SMOTE.
5. Optimisation avec GridSearchCV.
6. Comparaison entre baseline traditionnelle et modeles avances.
7. Deploiement via API et dashboard.

La regression logistique sert de reference traditionnelle, tandis que Random Forest et XGBoost ameliorent la qualite de discrimination dans le cadre du dataset synthetique. Les variables metier pertinentes comme les incidents de paiement, retards, apport personnel, charges et anciennete bancaire sont bien prises en compte par les modeles avances. Les predictions doivent donc etre presentees comme des resultats de prototype methodologique, a valider sur donnees bancaires reelles avant toute conclusion operationnelle.